Patrones con K-means

Integrantes:

Pablo Enrique Martinez Sanchez A01706352 Carlos Iñaki Román Martinez A01702712 Jesus Dassaef Lopez Barrios A01366815

Entendimiento de las columnas según el creador:

Game ID; Rated (T/F); Start Time; End Time; Number of Turns; Game Status; Winner; Time Increment; White Player ID; White Player Rating; Black Player ID; Black Player Rating; All Moves in Standard Chess Notation; Opening Eco (Standardised Code for any given opening, list here); Opening Name; Opening Ply (Number of moves in the opening phase)

link de consulta: https://www.kaggle.com/datasnaek/chess (https://www.kaggle.com/datasnaek/chess)

En este programa se eliminaron variables que no son relevantes para el proporsito del estudio, las variables eliminada son las siguientes: id, created_at, last_move, increment_status, white_id, black_id, moves, opening_eco, opening_name. Se quitaron las variables anteriores ya que no tienen relevancia para lo que se está buscando en el estudio.

Importamos las librerias necesarias para poder realizar el analísis estadístico.

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sb
import sklearn
from sklearn.cluster import KMeans
from sklearn.metrics import pairwise_distances_argmin_min
from sklearn.metrics import confusion_matrix, classification_report
from sklearn.preprocessing import scale
import sklearn.metrics as sm
from sklearn import datasets
%matplotlib inline
from mpl_toolkits.mplot3d import Axes3D
plt.rcParams['figure.figsize'] = (16, 9)
plt.style.use('ggplot')
```

Importamos la base de datos y la guardamos como dataframe para poder utilizarlo y imprimimos las primeras filas del archivo para corrborrar que funciona correctamente.

In [2]:
```
dataframe = pd.read_csv(r"gamesChess.csv") #Base de datos
dataframe.head()
```

Out[2]:

	id	rated	created_at	last_move_at	turns	victory_status	winner	increment_code	
0	TZJHLljE	0	1.500000e+12	1.500000e+12	13	outoftime	1	15+2	
1	l1NXvwaE	1	1.500000e+12	1.500000e+12	16	resign	2	5+10	
2	mIICvQHh	1	1.500000e+12	1.500000e+12	61	mate	1	5+10	
3	kWKvrqYL	1	1.500000e+12	1.500000e+12	61	mate	1	20+0	da
4	9tXo1AUZ	1	1.500000e+12	1.500000e+12	95	mate	1	30+3	

Sacamos la información estadística general de la base de datos.

In [3]:
```
dataframe.describe()
```

Out[3]:

	rated	created_at	last_move_at	turns	winner	white_rating	bl
count	20058.000000	2.005800e+04	2.005800e+04	20058.000000	20058.000000	20058.000000	20(
mean	0.805414	1.483208e+12	1.483208e+12	60.465999	1.548759	1596.631868	15
std	0.395891	2.831972e+10	2.831967e+10	33.570585	0.585120	291.253376	2
min	0.000000	1.376770e+12	1.376770e+12	1.000000	1.000000	784.000000	7
25%	1.000000	1.479640e+12	1.479642e+12	37.000000	1.000000	1398.000000	13
50%	1.000000	1.497030e+12	1.497030e+12	55.000000	2.000000	1567.000000	15
75%	1.000000	1.500708e+12	1.500708e+12	79.000000	2.000000	1793.000000	17
max	1.000000	1.504490e+12	1.504490e+12	349.000000	3.000000	2700.000000	27

In [4]:
```
#Vemos las partidas ganadas dependiendo del color y si hubo empates   1-Whites 2-
print(dataframe.groupby('winner').size())
```

```
winner
1    10001
2     9107
3      950
dtype: int64
```

Creamos histrogramas con la información de la base de datos donde se puede obvservar donde está el grossor de los jugadores en cada rublo.

In [5]:
```
dataframe.drop(['winner'],1).hist()
plt.show()
```

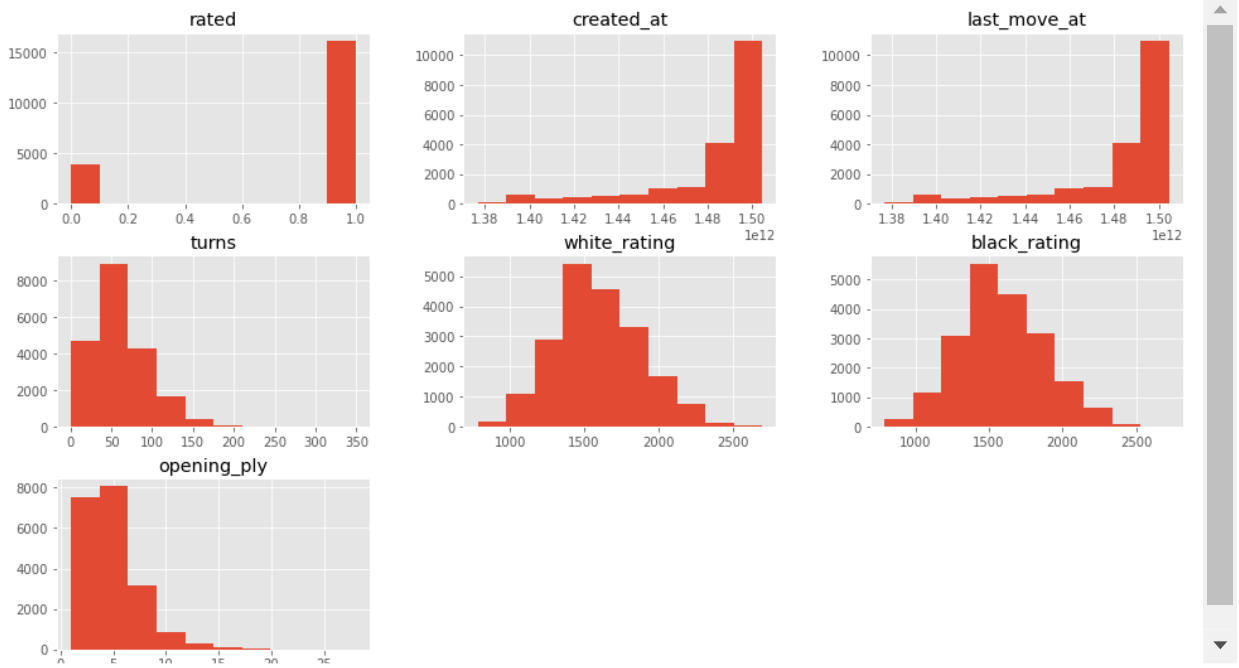

In [17]:
```
sb.pairplot(dataframe, hue="turns", diag_kind="hist");
```

Out[17]:
```
<seaborn.axisgrid.PairGrid at 0x21b0cce6d00>
```

In [7]:
```
#Para el ejercicio, sólo seleccionamos 3 dimensiones, para poder graficarlo
X = np.array(dataframe[["black_rating","white_rating","turns"]])
y = np.array(dataframe['winner'])
X.shape
```

Out[7]:
```
(20058, 3)
```

In [8]:
```
fig = plt.figure()
ax = Axes3D(fig)
colores=['blue','red','green','blue','cyan','yellow','orange','black','pink','brc
#NOTA: asignamos la posición cero del array repetida pues las categorias comienza
asignar=[]
for row in y:
 asignar.append(colores[row])
ax.scatter(X[:, 0], X[:, 1], X[:, 2], c=asignar,s=60);
```

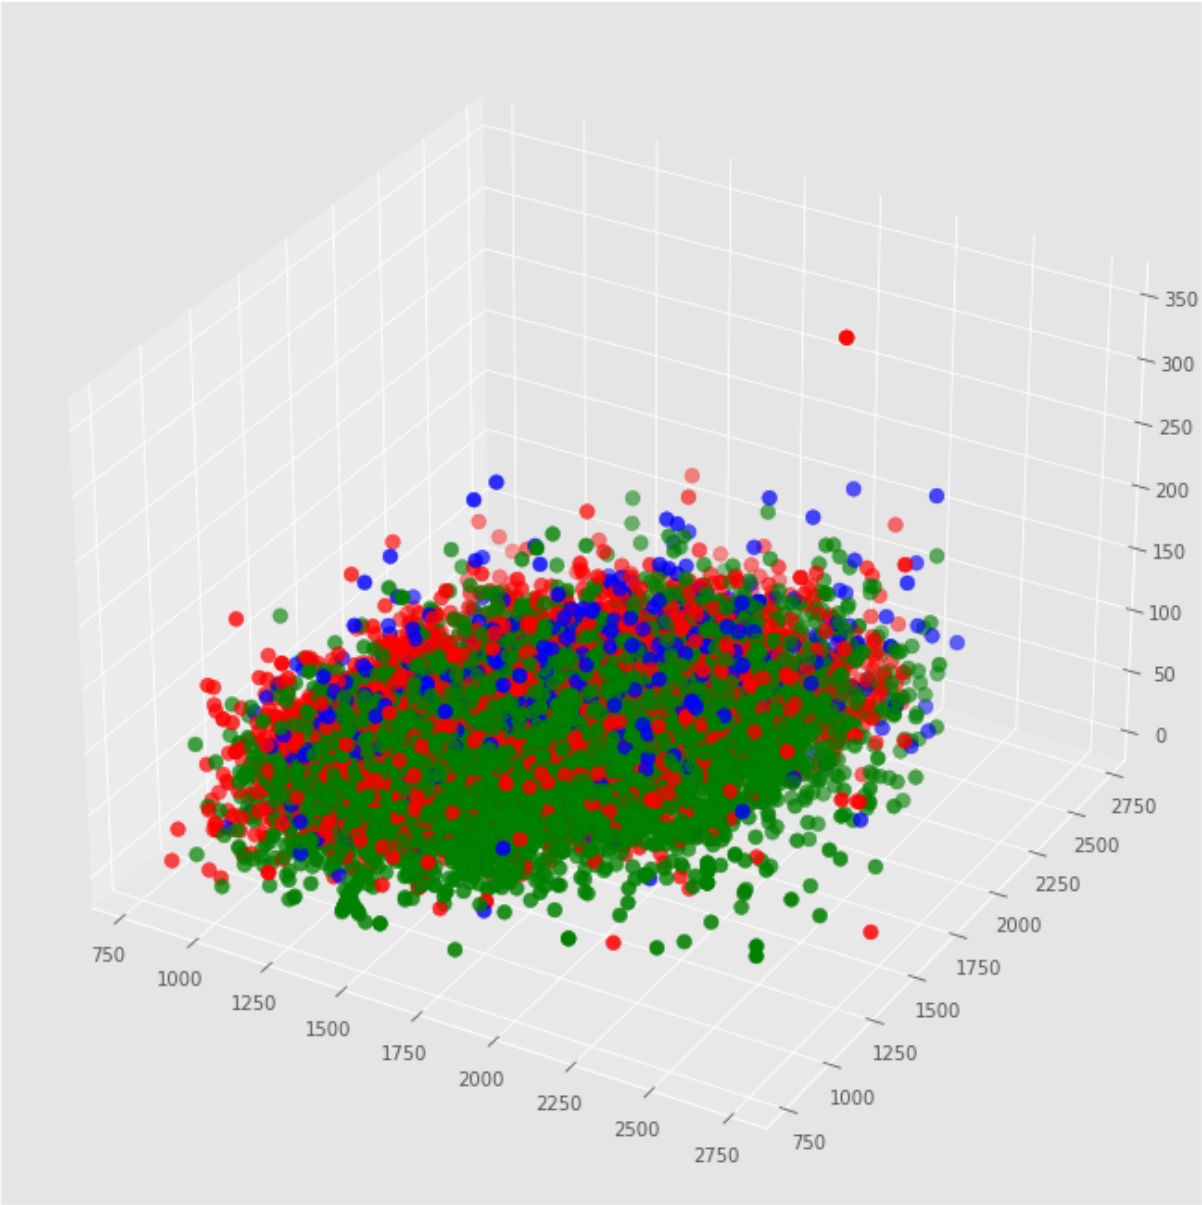

In [9]:
```
Nc = range(1, 20)
kmeans = [KMeans(n_clusters=i) for i in Nc]
kmeans
score = [kmeans[i].fit(X).score(X) for i in range(len(kmeans))]
score
plt.plot(Nc,score)
plt.xlabel('Number of Clusters')
plt.ylabel('Score')
plt.title('Elbow Curve')
plt.show()
```

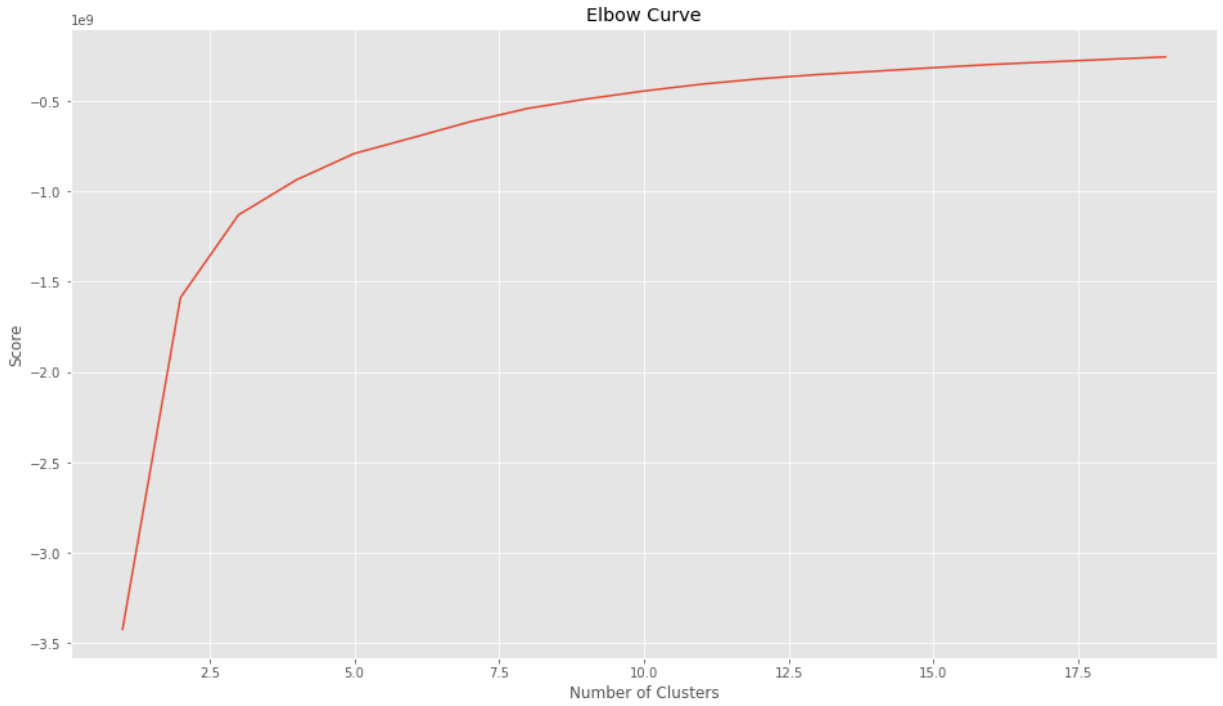

In [26]:
```
# Para el ejercicio, elijo 5 como un buen valor de K. Pero podría ser otro.
kmeans = KMeans(n_clusters=10).fit(X)
centroids = kmeans.cluster_centers_
print(centroids)
```

```
[[1701.85595921 1720.24410453   65.88017846]
 [1278.9045911  1413.33177905   54.76936872]
 [1378.96362229 1780.9876161    54.19814241]
 [1648.10545455 2196.51636364   54.60545455]
 [1531.95976879 1518.37734104   62.17919075]
 [1513.82233796 1241.3900463    53.48668981]
 [1959.153      1480.101        57.607     ]
 [2153.32191781 2124.48030822   70.02482877]
 [1146.97745773 1145.38572323   50.73324984]
 [1912.27184466 1891.1197411    69.40695793]]
```

In [30]:
```
# Obtenemos las etiquetas de cada punto de nuestros datos
labels = kmeans.predict(X)
# Obtenemos los centroids
C = kmeans.cluster_centers_
colores=['red','green','blue','cyan','yellow', "orange", "violet", "black", "mage
asignar=[]
for row in labels:
 asignar.append(colores[row])
fig = plt.figure()
ax = Axes3D(fig)
ax.scatter(X[:, 0], X[:, 1], X[:, 2], c=asignar,s=60)
ax.scatter(C[:, 0], C[:, 1], C[:, 2], marker='*', c=colores, s=1000);
```

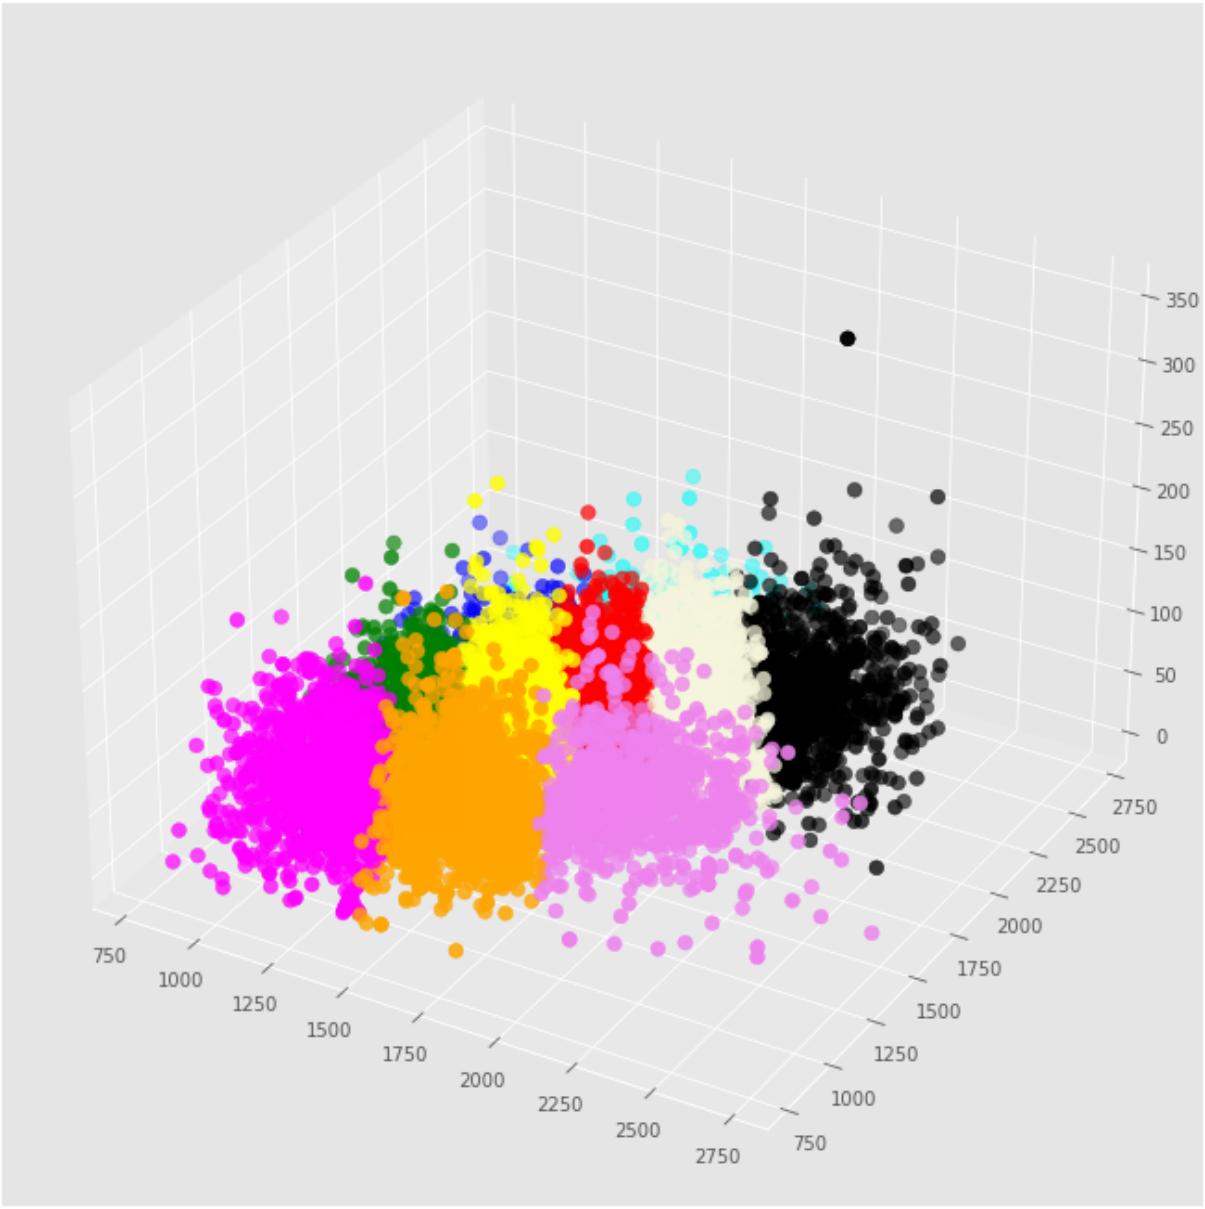

In [31]:
```
# Hacemos una proyección a 2D con los diversos ejes
f1 = dataframe['black_rating'].values
f2 = dataframe['white_rating'].values
plt.scatter(f1, f2, c=asignar, s=70)
plt.scatter(C[:, 0], C[:, 1], marker='*', c=colores, s=1000)
plt.show()
```

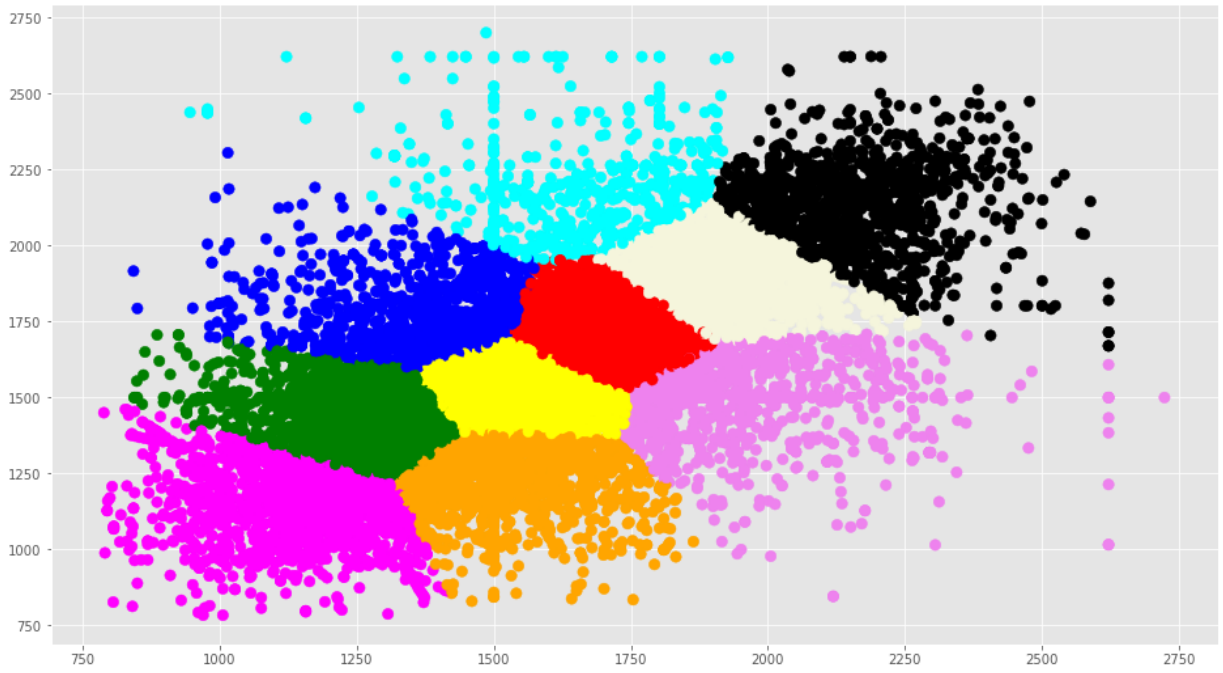

In [32]:
```
# Hacemos una proyección a 2D con los diversos ejes
f1 = dataframe['black_rating'].values
f2 = dataframe['turns'].values

plt.scatter(f1, f2, c=asignar, s=70)
plt.scatter(C[:, 0], C[:, 2], marker='*', c=colores, s=1000);
plt.show()
```

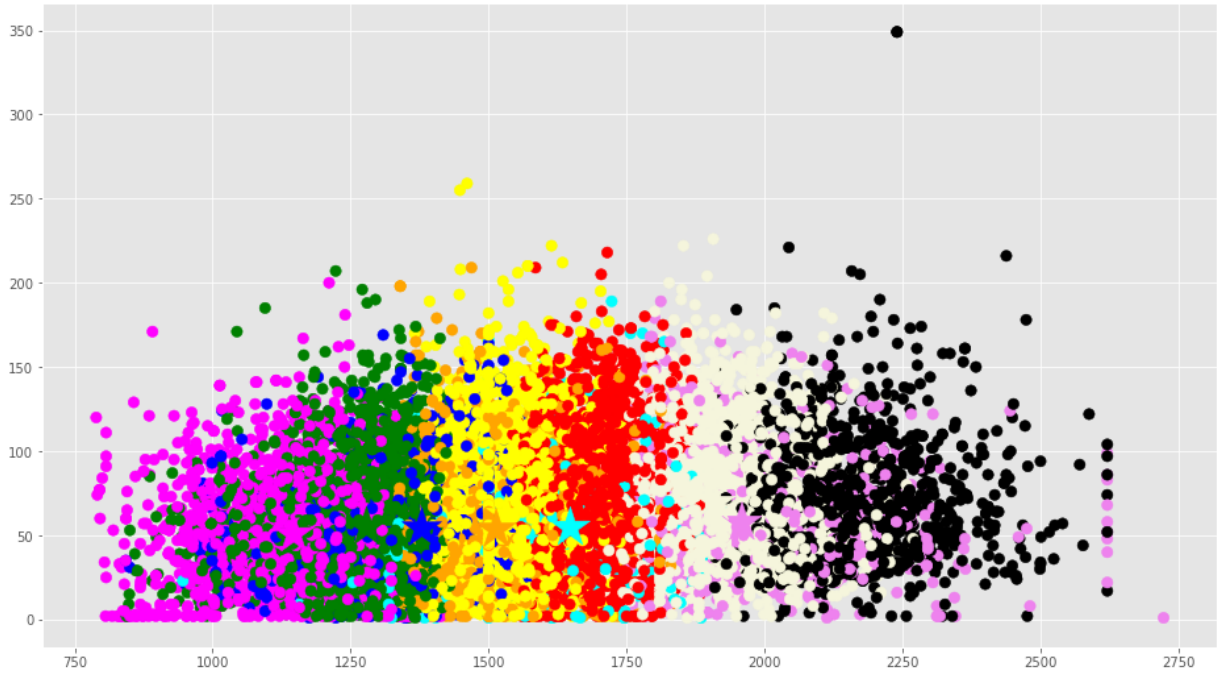

In [33]:
```
f1 = dataframe['white_rating'].values
f2 = dataframe['turns'].values
plt.scatter(f1, f2, c=asignar, s=70)
plt.scatter(C[:, 1], C[:, 2], marker='*', c=colores, s=1000)
plt.show()
```

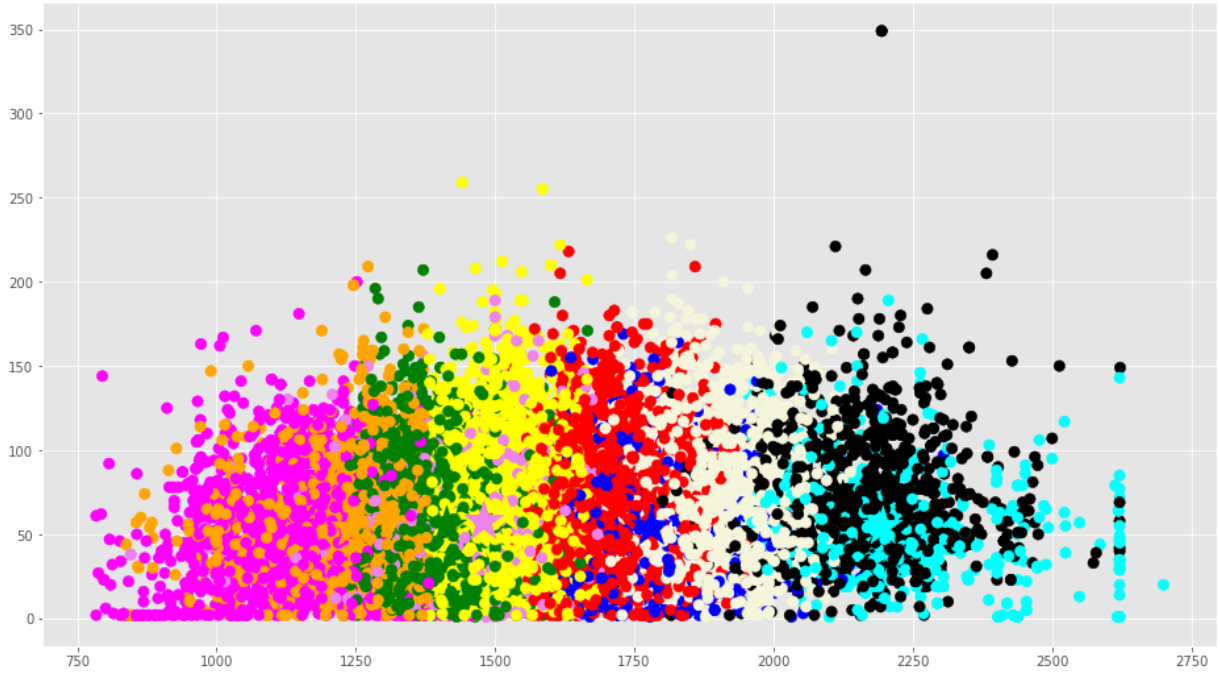

In [35]:
```
print (classification_report(y, labels));
```

	precision	recall	f1-score	support
0	0.00	0.00	0.00	0
1	0.63	0.18	0.28	10001
2	0.18	0.03	0.04	9107
3	0.05	0.03	0.03	950
4	0.00	0.00	0.00	0
5	0.00	0.00	0.00	0
6	0.00	0.00	0.00	0
7	0.00	0.00	0.00	0
8	0.00	0.00	0.00	0
9	0.00	0.00	0.00	0
accuracy			0.10	20058
macro avg	0.09	0.02	0.04	20058
weighted avg	0.40	0.10	0.16	20058

In [ ]:
```
¿Crees que estos centros puedan ser representativos de los datos? ¿Por qué?
- Los 10 centros son representativos de los datos ya que nos permite
ver en el plano dode se encuentra nuestras muestras más significativas.
En el caso de este estudio se ve claramente que los centros son representativos
de la información.

¿Cómo obtuviste el valor de k a usar?
- Al tener poco mas de 20,000 datos, tuvimos que utilizar 10 cómo nuestra k
para poder iferenciar de manera correcta nuestros conjuntos de datos. Se podría
utilizar más centros,sin embargo para el analísis hecho con estos es suficiente.

¿Los centros serían más representativos si usaras un valor más alto? ¿Más bajo?
- Al utilizar más centros la información se subdivide por lo que el centro tiene
menos puntos y es más exacto y representativo.


¿Qué distancia tienen los centros entre sí? ¿Hay alguno que este muy cercano
a otros?
- Al tener la agrupación de la información en una area "reducida",
los centros están cerca unos de otros, esto no es importancia
ya que cada centro es significativo de su región.



¿Qué pasaría con los centros si tuviéramos muchos outliers en el análisis
de cajas y bigotes?
-Lo que se podría observar es que los centros se verian muy juntos entre si
en los analísis de caja y bigotes.


¿Qué puedes decir de los datos basándose en los centros?
- Se denota que la agrupación de la información está en una sola región
del plano y del espacio,donde todos nuestros puntos están en el
primer cuadrante siendo todos positivos
```